

# Занятие 4

## Градиентный спуск. Линейные модели классификации.


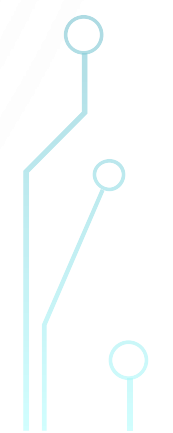
Елена Кантонистова

[elena.kantonistova@yandex.ru](mailto:elena.kantonistova@yandex.ru)

ВШЭ, 2021



# ПЛАН ЗАНЯТИЯ

- Градиентный спуск
  - Линейные классификаторы
  - Логистическая регрессия
  - Практика
- 
- 

# ОБУЧЕНИЕ ЛИНЕЙНОЙ РЕГРЕССИИ (НАПОМИНАНИЕ)

Обучающая выборка:

пусть  $x$  – объект ( $x_1, x_2, \dots, x_l$  - его признаки), а  $y$  – ответ на объекте (произвольное число).

Модель линейной регрессии:

$$a(x, w) = w_0 + w_1x_1 + w_2x_2 + \dots = \sum_{i=1}^l w_j x_j$$

# ГРАДИЕНТНЫЙ СПУСК

# ЛИНЕЙНАЯ РЕГРЕССИЯ

Обучение линейной регрессии - минимизация  
среднеквадратичной ошибки:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l (a(x_i) - y_i)^2 \rightarrow \min_w$$

# ЛИНЕЙНАЯ РЕГРЕССИЯ

Обучение линейной регрессии - минимизация  
среднеквадратичной ошибки:


$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l (a(x_i) - y_i)^2 \rightarrow \min_w$$

**Обучение других алгоритмов машинного обучения – это  
тоже минимизация какой-то (может быть, очень сложной)  
функции потерь!**

# ТЕОРЕМА О ГРАДИЕНТЕ


**Теорема.** Градиент – это вектор, в направлении которого функция быстрее всего растёт.

**Антиградиент (вектор, противоположный градиенту) – вектор, в направлении которого функция быстрее всего убывает.**



# ТЕОРЕМА О ГРАДИЕНТЕ

Антиградиент (вектор, противоположный градиенту) – вектор, в направлении которого функция быстрее всего убывает.






# МЕТОД ГРАДИЕНТНОГО СПУСКА

- Наша задача при обучении модели – найти такие веса  $w$ , на которых достигается **минимум функции ошибки**.


# МЕТОД ГРАДИЕНТНОГО СПУСКА

На каждом шаге (на каждой итерации метода) движемся в сторону антиградиента функции потерь!




# МЕТОД ГРАДИЕНТНОГО СПУСКА

На каждом шаге (на каждой итерации метода) движемся в сторону антиградиента функции потерь!




# МЕТОД ГРАДИЕНТНОГО СПУСКА

На каждом шаге (на каждой итерации метода) движемся в сторону антиградиента функции потерь!



# МЕТОД ГРАДИЕНТНОГО СПУСКА

На каждом шаге (на каждой итерации метода) движемся в сторону антиградиента функции потерь!




# МЕТОД ГРАДИЕНТНОГО СПУСКА

Формулу для обновления весов можно записать в векторном виде:


- Инициализируем веса  $w^{(0)}$ .
- На каждом следующем шаге обновляем веса по формуле:

$$w^{(k)} = w^{(k-1)} - \eta \nabla Q(w^{(k-1)})$$

# ГРАДИЕНТНЫЙ СПУСК





# ПРОБЛЕМА ВЫБОРА ГРАДИЕНТНОГО ШАГА





# ДЕМО: ЛИНЕЙНАЯ РЕГРЕССИЯ




The image features a light gray background with a subtle pattern of concentric circles. In the four corners, there are decorative elements resembling circuit board traces or neural network connections, consisting of thin blue lines and small circles.

# ЛИНЕЙНАЯ КЛАССИФИКАЦИЯ


# БИНАРНАЯ КЛАССИФИКАЦИЯ

$y_1, y_2, \dots, y_n$  - ответы (**+1 или -1**).



# БИНАРНАЯ КЛАССИФИКАЦИЯ

$y_1, y_2, \dots, y_n$  - ответы (**+1 или -1**).



Как выглядит модель линейного классификатора:  $a(x, w) = ?$

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Модель линейного классификатора:

$$a(x, w) = \textit{sign}\left(\sum_{j=1}^l w_j x_j\right)$$

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Модель линейного классификатора:

$$a(x, w) = \textit{sign}\left(\sum_{j=1}^l w_j x_j\right)$$

- Если сумма  $> 0$ , то  $\textit{sign}(\text{суммы}) = +1$ , то есть объект отнесён к положительному классу
- если сумма  $< 0$ , то  $\textit{sign}(\text{суммы}) = -1$ , то есть объект отнесён к отрицательному классу

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Модель линейного классификатора:

$$a(x, w) = \textit{sign}\left(\sum_{j=1}^l w_j x_j\right)$$

- Если сумма  $> 0$ , то  $\textit{sign}(\text{суммы}) = +1$ , то есть объект отнесён к положительному классу
- если сумма  $< 0$ , то  $\textit{sign}(\text{суммы}) = -1$ , то есть объект отнесён к отрицательному классу
- значит,  $\sum_{j=1}^l w_j x_j = 0$  – *уравнение разделяющей границы* между классами. *Это уравнение плоскости* (или прямой в двумерном случае), поэтому *классификатор является линейным.*

# БИНАРНАЯ КЛАССИФИКАЦИЯ


Модель линейного классификатора:

$$a(x, w) = \text{sign}\left(\sum_{j=1}^l w_j x_j\right)$$

Уравнение

$$\sum_{j=1}^l w_j x_j = 0$$

– уравнение плоскости  
(или прямой).





# ОБУЧЕНИЕ КЛАССИФИКАТОРА

*Как обучить линейный классификатор?*

# ОБУЧЕНИЕ КЛАССИФИКАТОРА

- Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [a(x_i) \neq y_i] \rightarrow \min,$$

где  $[a(x_i) \neq y_i] = 1$ , если предсказание на объекте неверное, то есть  $a(x_i) \neq y_i$ , и 0 иначе.

# ОБУЧЕНИЕ КЛАССИФИКАТОРА

- Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^n [a(x_i) \neq y_i] \rightarrow \min,$$

где  $[a(x_i) \neq y_i] = 1$ , если предсказание на объекте неверное, то есть  $a(x_i) \neq y_i$ , и 0 иначе.

Для обучения классификатора можно использовать и другие функции потерь. Далее рассмотрим несколько классических моделей классификации.



# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

Хотим предсказывать не только классы, но и вероятности классов.

- Линейная регрессия:  $a(x, w) = (x, w)$
- Логистическая регрессия:  $a(x, w) = \sigma((x, w))$ ,


где  $\sigma(z) = \frac{1}{1+e^{-z}}$  - сигмоида (логистическая функция)

# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

- Линейная регрессия:  $a(x, w) = (x, w) \in \mathbb{R}$
- Логистическая регрессия:  $a(x, w) = \sigma((x, w))$ ,

где  $\sigma(z) = \frac{1}{1+e^{-z}}$  - сигмоида (логистическая функция),

$\sigma(z) \in (0; 1)$ .



Логистическая регрессия:  $a(x, w) = \frac{1}{1+e^{-(x,w)}}$


# ВЕРОЯТНОСТНЫЙ СМЫСЛ

- $a(x, w)$  – вероятность того, что  $y = +1$  на объекте  $x$ , то есть

$$a(x, w) = P(y = +1|x; w)$$

# РАЗДЕЛЯЮЩАЯ ГРАНИЦА

Предсказываем  $y = +1$ , если  $a(x, w) \geq 0.5$ .



$a(x, w) = g((x, w)) \geq 0.5$ , если  $(x, w) \geq 0$ .

Получаем, что

- $y = +1$  при  $(x, w) \geq 0$
- $y = -1$  при  $(x, w) < 0$ ,

т.е.  $(x, w) = 0$  – разделяющая гиперплоскость.



# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

**Логистическая регрессия - это линейный классификатор!**

# ФУНКЦИЯ ПОТЕРЬ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

Если взять квадратичную функцию потерь

$$L(a, y) = (a - y)^2,$$

то возникнут проблемы:

- $Q(a, X) = \frac{1}{l} \sum_{i=1}^l \left( \frac{1}{1+e^{-(x,w)}} - y \right)^2$  - не выпуклая функция  
(*можем не попасть в глобальный минимум при оптимизации*)

# ФУНКЦИЯ ПОТЕРЬ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

Если взять квадратичную функцию потерь

$$L(a, y) = (a - y)^2,$$


то возникнут проблемы:

- $Q(a, X) = \frac{1}{l} \sum_{i=1}^l \left( \frac{1}{1+e^{-(x,w)}} - y \right)^2$  - не выпуклая функция  
(*можем не попасть в глобальный минимум при оптимизации*)
- *На совсем неправильном предсказании маленький штраф* (пусть предсказали вероятность 0% на объекте класса  $y = +1$ , тогда штраф всего  $(1 - 0)^2 = 1$ )


# ФУНКЦИЯ ПОТЕРЬ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

Возьмем логистическую функцию потерь (log-loss):

$$Q(w) = - \sum_{i=1}^l ([y_i = +1] \cdot \log(a(x_i, w)) + [y_i = -1] \cdot \log(1 - a(x_i, w)))$$



# ЛОГИСТИЧЕСКАЯ ФУНКЦИЯ ПОТЕРЬ



- если  $a(x, w) = 1$  и  $y = +1$ , то штраф  $L(a, y) = 0$
- если  $a(x, w) \rightarrow 0$ , а  $y = +1$ , то штраф  $L(a, y) \rightarrow +\infty$